

Guía de Actividades Práctico-Experimentales Nro. 004

1. Datos Generales

Nombre	• Domenica Narvaez • José Valencia • Valeria Ágila • Diyer Torres • Sherman Abarca • Gabriel Suarez
Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	1
Resultado de aprendizaje de la unidad	Calcula probabilidades y momentos de variables aleatorias discretas, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	004
Título de la Práctica	Momentos Estadísticos: Esperanza Matemática, Varianza y Análisis de Tendencia Central con Python
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 005 de abril 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Calcular** teórica y computacionalmente la esperanza matemática ($E[X]$) y la varianza ($V[X]$) de variables aleatorias discretas y continuas utilizando la librería scipy.stats en Python.
- **Aplicar** el análisis de tendencia central y dispersión sobre el conjunto de datos (dataset) regional seleccionado para el Proyecto Integrador, facilitando el hito de la semana.
- **Validar** los conceptos adquiridos en la clase invertida de la semana 4 (variables aleatorias) integrándolos en la resolución de problemas (ABP).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Inicio:

Enfoque PID-2025: ABP y ABI. Duración: 120 min. Modalidad: grupal (2-3 estudiantes).

Desarrollo:

Enfoque PID-2025:

ABP (Aprendizaje Basado en Problemas): Los estudiantes resolverán el desafío de calcular y dar sentido a los momentos estadísticos de su propio dataset regional, enfrentándose a problemas reales de distribución de datos (sesgos, valores atípicos).

ABI (Aprendizaje Basado en Investigación): Búsqueda guiada en la documentación oficial de Scipy y Pandas para justificar la elección de funciones (ej. ddof=1 en varianza muestral).

Duración sugerida: 120 min. (presencial).

Modalidad: Grupos de trabajo (para el Proyecto Integrador) con ejecución técnica individual.

Procedimiento / Metodología

Tarea 1: Validación de Clase Invertida (Semana 4)

Dado el feriado del 01 de mayo, esta sección evalúa la participación en la clase invertida.

Abra el Jupyter Notebook generado en el trabajo autónomo de la Semana 4.

Asegúrese de que el bloque de código contenga su modificación personal (ej. simulación de la variable de Bernoulli).

Ejecute el script y presente visualmente al docente la PMF (Función de Masa de Probabilidad) generada para validar su puntaje de participación.

Tarea 2: Cálculo Teórico y Simulación de Esperanza Matemática ($E[X]$)

Recordemos que para una variable discreta, la esperanza se define como

$$E[X] = \sum x \cdot P(X = x), \quad \text{y} \quad \text{para una continua como} \quad E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx.$$

1. Abra un nuevo Jupyter Notebook llamado **APE_005_Momentos.ipynb**.
2. Escriba y ejecute el siguiente script para calcular momentos usando la abstracción de `scipy.stats`.

```
import numpy as np

from scipy.stats import binom, norm

# 1. Variable Aleatoria Discreta (Distribución Binomial)

n_ensayos, p_exito = 10, 0.4

var_discreta = binom(n_ensayos, p_exito)

# Cálculo de Momentos Teóricos (Mean, Variance)

esperanza_d, varianza_d = var_discreta.stats(moments='mv')

print(f"--- Variable Discreta (Binomial n={n_ensayos}, p={p_exito}) ---")

print(f"Esperanza E[X]: {esperanza_d}")

print(f"Varianza V[X]: {varianza_d}\n")

# 2. Variable Aleatoria Continua (Distribución Normal)

mu, sigma = 50, 5 # Media y Desviación Estándar

var_continua = norm(loc=mu, scale=sigma)

esperanza_c, varianza_c = var_continua.stats(moments='mv')

print(f"--- Variable Continua (Normal mu={mu}, sigma={sigma}) ---")
```



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de
Computación

```
print(f"Esperanza E[X]: {esperanza_c}")  
print(f"Varianza V[X]: {varianza_c}")
```

Tarea 3: Hito del Proyecto - Análisis de Tendencia Central y Dispersión

Aplique los conceptos teóricos a su conjunto de datos regional.

Cargue su dataset regional utilizando pandas.

Identifique al menos dos variables cuantitativas clave para su estudio.

Desarrolle un script que calcule la media muestral () y la varianza muestral (). Utilice la formulación insesgada donde la suma de cuadrados se divide por .

```
import pandas as pd  
import seaborn as sns  
import matplotlib.pyplot as plt  
  
# Carga de datos (Reemplace con la ruta de su dataset regional)  
  
# df_regional = pd.read_csv('datos_loja.csv')  
  
# SIMULACIÓN (A falta del dataset real en esta guía, usamos datos simulados para ilustrar)  
np.random.seed(42)  
df_regional = pd.DataFrame({  
    'Temperatura_Promedio': np.random.normal(loc=18.5, scale=2.1, size=300),  
    'Precipitacion_mm': np.random.exponential(scale=15.0, size=300)  
})  
  
# Cálculo de Estadísticos usando Pandas  
columna_obj = 'Temperatura_Promedio'  
media_muestral = df_regional[columna_obj].mean()  
varianza_muestral = df_regional[columna_obj].var(ddof=1) # ddof=1 para muestra insesgada  
print(f"Análisis del Dataset Regional - Variable: {columna_obj}")  
print(f"Media Muestral (Estimador de E[X]): {media_muestral:.2f}")  
print(f"Varianza Muestral (Estimador de V[X]): {varianza_muestral:.2f}")  
  
# Visualización para el hito del proyecto  
plt.figure(figsize=(8, 5))  
sns.histplot(df_regional[columna_obj], kde=True, color='blue', stat='density')  
plt.axvline(media_muestral, color='red', linestyle='--', label=f'Media: {media_muestral:.2f}')  
plt.title('Distribución de Frecuencias y Tendencia Central')  
plt.legend()
```

```
plt.show()
```

Tarea 4: ABI - Documentación y Discusión Grupal

Investigue en la documentación de Pandas qué significa el parámetro `ddof=1` utilizado en la función `.var()`. Redacte un breve párrafo (en formato Markdown dentro de su Jupyter Notebook) justificando estadísticamente por qué se utiliza en lugar de al trabajar con una muestra de su dataset regional, utilizando los conceptos de estimador insesgado. Utilizar la librería `itertools` de Python para generar espacios muestrales de experimentos aleatorios.

Metodología activa empleada: ABP (Aprendizaje Basado en Problemas) – según enfoque PID-2025.

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (`itertools`).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- **¿Cuál es la diferencia matemática y conceptual entre la esperanza matemática teórica calculada a partir de un modelo de probabilidad (ej. `binom.stats()`) y la media muestral calculada de un `DataFrame` de pandas?**

La esperanza matemática es un valor teórico del modelo probabilístico por otra parte la media muestral es un estadístico calculado a partir de datos observados. La primera depende de la distribución asumida y la segunda depende de la muestra concreta que se tenga. En una distribución de Poisson con parámetro λ , esa esperanza es $\mathbb{E}[X] = \lambda$. La media muestral de un `DataFrame` de pandas es el promedio de los datos observados, es decir, $\bar{x} = \frac{1}{n} \sum x_i$. La primera es un valor del modelo; la segunda es un valor calculado desde datos reales.

Diferencia matemática:

Si $X \sim \text{Poisson}(\lambda)$, entonces el modelo dice que el número promedio de eventos por intervalo es λ . En cambio, si tienes una columna de pandas con conteos observados y haces `df['conteos'].mean()`, obtienes la media de esa muestra concreta, no el parámetro teórico del proceso.

Por ejemplo, si el modelo de Poisson tiene $\lambda = 4$, la esperanza teórica es 4. Pero una muestra observada podría dar 3.8, 4.2 o 5.1, porque la media muestral cambia de una muestra a otra.

Diferencia conceptual

La esperanza teórica responde: "¿cuál sería el promedio a largo plazo se repite el proceso muchas veces bajo este modelo?". La media muestral responde: "¿cuál es el promedio de los datos que ya se observó?". En pocas palabras, la esperanza pertenece al modelo; la media muestral pertenece a la muestra. Por eso la esperanza es fija si el parámetro del modelo no cambia, mientras que la media muestral depende de los datos disponibles.

- **Demuestre teóricamente, utilizando las propiedades de la esperanza, por qué la varianza se puede reescribir como** $V[X] = E[X^2] - (E[X])^2$.

Demostración Paso a Paso

Paso	Descripción y Justificación
1. Definición Formal	Partimos de la definición fundamental de la varianza: $V[X] = E[(X - E[X])^2]$
2. Notación Simplificada	Para facilitar la lectura, definimos la media como una constante $\mu = E[X]$: $V[X] = E[(X - \mu)^2]$
3. Expansión del Binomio	Desarrollamos el cuadrado del binomio $(a - b)^2 = a^2 - 2ab + b^2$: $(X - \mu)^2 = X^2 - 2X\mu + \mu^2$ Por lo tanto: $V[X] = E[X^2 - 2X\mu + \mu^2]$
4. Propiedad de Linealidad	Aplicamos la propiedad de linealidad de la esperanza, donde $E[A + B] = E[A] + E[B]$: $V[X] = E[X^2] - E[2X\mu] + E[\mu^2]$
5. Propiedad de las Constantes	Como μ es una constante, sabemos que $E[c \cdot X] = c \cdot E[X]$ y $E[c] = c$: • $E[2X\mu] = 2\mu E[X]$

Paso	Descripción y Justificación
	$E[\mu^2] = \mu^2$ Sustituyendo: $V[X] = E[X^2] - 2\mu E[X] + \mu^2$
6. Sustitución Final	Recordamos que $\mu = E[X]$: $V[X] = E[X^2] - 2(E[X])(E[X]) + (E[X])^2$ $V[X] = E[X^2] - 2(E[X])^2 + (E[X])^2$
7. Resultado	Combinando los términos semejantes: $V[X] = E[X^2] - (E[X])^2$

Conclusión

La varianza representa el momento de segundo orden menos el cuadrado del primer momento (la media). Esta identidad es fundamental para el cálculo práctico de la varianza en estadística y probabilidad.

- **Si la varianza calculada en su variable regional es inusualmente alta, ¿qué implicaciones prácticas tiene esto sobre la confiabilidad de la media como predictor del comportamiento de esos datos en la región de Loja?**

Si la varianza es muy alta en Loja nos indica una heterogeneidad extrema, indicando que la media pierde validez como predictor porque los datos están muy dispersos o influenciados por valores atípicos, generando así un espejismo estadístico en donde el promedio no representa la realidad de la mayoría. Para recobrar la fiabilidad tendrías que usar la mediana o seguimiento de datos.

- **Revise el parámetro ddof de la función var() en Pandas. ¿Qué ocurre con el estimador de la varianza si establecemos ddof=0 y en qué escenario específico de población poblacional esto sería matemáticamente correcto?**

Cuando en la función `.var()` de Pandas se establece `ddof = 0`, la varianza se calcula dividiendo entre n en lugar de $n - 1$. Esto hace que el estimador sea la varianza poblacional, no la muestral.

En este caso, el estimador se vuelve sesgado si los datos corresponden solo a una muestra, ya que tiende a subestimar la variabilidad real de la

población. Esto ocurre porque no se está corrigiendo la pérdida de grados de libertad al usar la media muestral [5].

El uso de $ddof = 0$ es matemáticamente correcto únicamente cuando se trabaja con toda la población completa, es decir, cuando no se está haciendo inferencia sino un cálculo exacto sobre todos los datos existentes. Por ejemplo, si se tienen todos los valores de una población (como todas las temperaturas registradas en un conjunto completo sin muestreo), entonces no es necesario ajustar los grados de libertad [4].

En cambio, cuando se trabaja con una muestra, lo correcto es usar $ddof = 1$, ya que proporciona un estimador insesgado de la varianza poblacional.

- **Observe el histograma generado en la Tarea 3. ¿De qué manera el cálculo combinado de la esperanza matemática (media) y la varianza apoyan en la identificación estadística de valores atípicos (outliers) para la posterior limpieza de su Proyecto Integrador?**


El análisis del histograma evidencia que la combinación de la media y la varianza es clave para identificar valores atípicos (outliers) de manera objetiva. La media funciona como un punto de referencia central que representa el comportamiento promedio de los datos, mientras que la varianza (y la desviación estándar) permite medir qué tan alejados están los valores respecto a ese centro.

En el dataset de remuneraciones de Loja, se observa que la media está desplazada hacia la derecha, lo que indica una asimetría positiva. Esto sugiere la presencia de valores altos que influyen en el promedio y generan una cola larga en la distribución.

Al combinar ambos estadísticos, se pueden establecer límites, por ejemplo usando ± 3 desviaciones estándar alrededor de la media. Los valores que superan ese rango, como remuneraciones cercanas a los \$4,000, se consideran atípicos.

Este procedimiento permite pasar de una observación visual a un criterio técnico, facilitando la limpieza de datos. Así, se puede decidir si esos valores son reales o errores, reduciendo sesgos y mejorando la representatividad del análisis.

En síntesis, la media define el valor central esperado y la varianza el rango de variación, y juntas permiten identificar de forma rigurosa los outliers.



Dataset cargado: 2883 registros, 12 columnas

Variable: Remuneración mensual unificada
n (tamaño muestral) : 2883
Media muestral $\bar{x}$: 713.81
Varianza muestral s^2 : 70276.27
Desviación estándar s : 265.10

Variable: Total ingresos adicionales
n (tamaño muestral) : 2883
Media muestral $\bar{x}$: 128.13
Varianza muestral s^2 : 5685.30
Desviación estándar s : 75.40

8. Rúbrica de Evaluación

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
1. Evaluación Clase Invertida (Semana 4)	2.0 puntos	Ejecución exitosa del script de la V.A. modificado (demostración en pantalla de PMF/PDF).
2. Momentos con Scipy	2.0 puntos	Bloque de código de la Tarea 2 funcional, sin errores de sintaxis y mostrando $E[X]$ y $V[X]$ exactos.
3. Hito: Análisis de Tendencia Central	3.0 puntos	Cálculo correcto de la media y varianza en el dataset regional propio, acompañado de visualización (histograma con línea de media).
4. Justificación ABI (Parámetro ddof)	1.5 puntos	Párrafo escrito en el notebook explicando el concepto de <i>grados de libertad</i> y el <i>estimador insesgado</i> .



5. Preguntas de Control	1.5 puntos	Respuestas redactadas en el Notebook (sección final) demostrando análisis crítico, uso de notación matemática y comprensión del negocio/región.
Total	10.0 puntos	

9. Bibliografía

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

[4] M. G. Juárez, "Varianza muestral", Probabilidad y Estadística, 16-ene-2023. [En línea]. Disponible en: <https://www.probabilidadyestadistica.net/varianza-muestral/>. [Consultado: 05-may-2026].

[5] "pandas.DataFrame.var — pandas 3.0.2 documentation", Pydata.org. [En línea]. Disponible en: <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.var.html>. [Consultado: 05-may-2026].

[6] C. M. Grinstead y J. L. Snell, *Probabilidad Introductoria*. LibreTexts. [En línea]. Disponible en: https://espanol.libretexts.org/Estadisticas/Teoria_de_Probabilidad/Libro%3A_Probabilidad_Introductoria%28Grinstead_y_Snell%29/06%3A_Valores_esperados_y_varianzas/6.02%3A_Varianza_de_variables_aleatorias_discretas. Accedido: 5-may-2026.

[7] S. M. Ross, *Introduction to Probability and Statistics for Engineers and Scientists*, 6th ed. Academic Press, 2020.



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	