



Guía de Actividades **Práctico-Experimentales** Nro. 005

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	1
Resultado de aprendizaje de la unidad	Calcula probabilidades y momentos de variables aleatorias discretas, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	005
Título de la Práctica	Distribuciones Discretas Notables: Modelado y Simulación de Procesos de Bernoulli y Eventos Raros
Nombre del Docente	Cristian Ramiro Narváez Guillén
Integrantes	• Sherman Abarca • Valeria Aguila • Domenica Narvaez • Diyer Torres • Gabriel Suarez • José Valencia
Fecha	Martes 12 de mayo del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Modelar** fenómenos estocásticos discretos calculando la Función de Masa de Probabilidad (PMF) y la Función de Distribución Acumulada (CDF) utilizando el módulo `scipy.stats` en Python.
- **Aplicar** el modelo de distribución de Poisson para analizar variables de conteo (eventos por unidad de tiempo/espacio) dentro del conjunto de datos regional del Proyecto Integrador (ABP).
- **Investigar** y demostrar computacionalmente el teorema del límite que rige la aproximación de la distribución Binomial a la distribución de Poisson (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).

- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional en formato .csv o .xlsx (seleccionado y limpiado en las semanas 1 y 2).
- Conexión a Internet estable y continua.
- Navegador web actualizado (Chrome, Firefox o Edge).
- Repositorio del proyecto (GitHub/GitLab) para control de versiones (opcional, pero recomendado).

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

Enfoque PID-2025:

- ABP (Aprendizaje Basado en Problemas): El estudiante debe identificar qué variables de su propio dataset regional cumplen con los supuestos de las distribuciones discretas (conteo, independencia) y justificar el ajuste de estos modelos teóricos a datos empíricos reales.
- ABI (Aprendizaje Basado en Investigación): Indagación matemática sobre los límites asintóticos ($n \rightarrow \infty, p \rightarrow 0$) que permiten la convergencia entre distribuciones de probabilidad.
- Duración sugerida: 120 min. (presencial).
- Modalidad: Grupos de trabajo (para contextualización del proyecto) con programación e informe técnico individual.

Tarea 1: Modelado Computacional de la Distribución Binomial

La distribución Binomial modela el número de éxitos x en n ensayos independientes de Bernoulli, con probabilidad de éxito p . Su PMF está dada por:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$$

Abra un nuevo Jupyter Notebook llamado APE_006_Distribuciones.ipynb.

Suponga un escenario de control de calidad de software donde un lote de 20 microservicios tiene una probabilidad del 15% de fallar bajo estrés. Escriba y ejecute el siguiente código:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import binom
```

```
# Parámetros del modelo Binomial
```

```
n_ensayos = 20
```

```
p_falla = 0.15
```

```
# Dominio de la variable aleatoria (0 a n)
```

```
x = np.arange(0, n_ensayos + 1)
```

```
# Cálculo de PMF (Función de Masa) y CDF (Función Acumulada)
```

```
pmf_binomial = binom.pmf(x, n_ensayos, p_falla)
```

```
cdf_binomial = binom.cdf(x, n_ensayos, p_falla)
```

```
# Visualización
```

```
fig, ax = plt.subplots(1, 2, figsize=(14, 5))
```

```
# Gráfico PMF
```

```
ax[0].vlines(x, 0, pmf_binomial, colors='b', lw=5, alpha=0.5)
```

```
ax[0].plot(x, pmf_binomial, 'bo', ms=8)
```

```
ax[0].set_title(f'PMF - Binomial (n={n_ensayos}, p={p_falla})')
```

```
ax[0].set_xlabel('Número de fallos (x)')
```

```
ax[0].set_ylabel('P(X = x)')
```

```
ax[0].grid(True, alpha=0.3)
```

```
# Gráfico CDF
```

```
ax[1].step(x, cdf_binomial, where='post', color='r', lw=2)
```

```
ax[1].plot(x, cdf_binomial, 'ro', alpha=0.5)
```

```
ax[1].set_title('CDF - Distribución Acumulada')
```

```
ax[1].set_xlabel('Número de fallos (x)')
```

```
ax[1].set_ylabel('P(X <= x)')
```

```
ax[1].grid(True, alpha=0.3)
```

```
plt.tight_layout()
```

```
plt.show()
```

```
# Cálculo de probabilidad específica:  $P(X \leq 3)$ 
```

```
prob_max_3 = binom.cdf(3, n_ensayos, p_falla)
```

```
print(f'La probabilidad de tener 3 fallos o menos es: {prob_max_3:.4f}')
```

Tarea 2: Modelado de la Distribución de Poisson (Eventos Raros)

La distribución de Poisson modela el número de eventos que ocurren en un intervalo de tiempo o espacio continuo, con una tasa media conocida λ . Su PMF es:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

Suponga que los servidores de la universidad en Loja reciben en promedio $\lambda = 4.5$ peticiones de acceso erróneas por minuto.

Basándose en la estructura del código de la Tarea 1, implemente la simulación utilizando `scipy.stats.poisson`. Grafique únicamente la PMF evaluando desde $x = 0$ hasta $x = 15$.

Calcule mediante código la probabilidad exacta de recibir exactamente 6 peticiones erróneas en un minuto: $P(X = 6)$.

Tarea 3: Hito del Proyecto - Identificación de Variables de Conteo (ABP)

Cargue su dataset regional en pandas.

Identifique una variable discreta que represente un "conteo" (ej. número de accidentes semanales en Loja, número de transacciones diarias, cantidad de clientes por hora).

Calcule la media muestral ($\bar{x}$) de esa variable y asuma que es el parámetro λ para un modelo de Poisson teórico.

Genere un gráfico superponiendo el histograma de densidad de su variable empírica contra la línea de la PMF teórica de Poisson generada en `scipy`. Discuta visualmente si los datos reales siguen esta distribución.

Tarea 4: ABI - Aproximación Binomial a Poisson

Investigue bajo qué condiciones matemáticas una distribución Binomial se aproxima a una de Poisson.

Redacte un bloque Markdown explicando la relación $\lambda = n \cdot p$ cuando $n \rightarrow \infty$ y $p \rightarrow 0$.

Escriba un pequeño script en Python que calcule $P(X = 3)$ usando un modelo Binomial con $n = 1000$ y $p = 0.003$, y compare el resultado imprimiendo también el valor de $P(X = 3)$ en un modelo de Poisson donde $\lambda = 1000 \cdot 0.003 = 3$. Demuestre que los valores son casi idénticos.

6. Resultados esperados:

- Comprensión de los conceptos básicos de probabilidad y teoría de conjuntos.
- Capacidad para generar espacios muestrales usando Python (`itertools`).
- Diferenciación entre los enfoques clásico, empírico y subjetivo de probabilidad.
- Verificación empírica de las probabilidades teóricas mediante simulación.
- Dataset regional seleccionado y documentado para el proyecto integrador.

7. Preguntas de Control:

- **Matemática y conceptualmente, ¿por qué la Función de Distribución Acumulada (CDF) de una variable aleatoria discreta tiene una gráfica en forma de "escalera" (step function) a diferencia de las funciones continuas?**

La Función de Distribución Acumulada (CDF) de una variable aleatoria discreta tiene forma de "escalera" porque la probabilidad no se distribuye de manera continua, sino únicamente en ciertos valores específicos.

En una variable discreta, los valores posibles están "separados". Esto significa que la función va acumulando probabilidades conforme avanzamos en el eje x . Entre dos valores posibles no ocurre ningún cambio en la probabilidad, solo cuando llegamos a un valor permitido de la variable, la función "salta"

De manera matemática lo podemos representar de la siguiente forma:

Si tenemos una variable discreta que:

$$P(X = 1) = 0.3, \quad P(X = 2) = 0.5, \quad P(X = 3) = 0.2$$

La CDF seria:

$$F(x) = \begin{cases} 0 & x < 1 \\ 0.3 & 1 \leq x < 2 \\ 0.8 & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$

Observa que:

- Antes de 1, no hay probabilidad acumulada.
- En $x=1$, la función salta a 0.3.
- Entre 1 y 2, permanece constante.
- En $x=2$, vuelve a saltar hasta 0.8.

La razón matemática es que:

$$F(x) = \sum_{t \leq x} P(X = t)$$

- **Analizando los supuestos del experimento de Bernoulli, si extraemos cartas de una baraja sin reemplazo buscando ases, ¿podemos modelar este escenario con una distribución Binomial? Justifique estadísticamente su respuesta.**

No, no se puede modelar correctamente con una Distribución Binomial.

Fundamento estadístico

La distribución Binomial requiere que se cumplan todos los supuestos del experimento de Bernoulli:

Supuesto	¿Se cumple?	Análisis
Número fijo de ensayos n	Sí	Definimos cuántas cartas extraer
Solo dos resultados posibles (éxito/fracaso)	Sí	As o no-As
Probabilidad de éxito p constante	No	Cambia en cada extracción
Ensayos independientes	No	Cada extracción afecta la siguiente

El problema central: dependencia e p variable

En una baraja estándar de 52 cartas con 4 ases, la probabilidad de obtener un as en la primera extracción es:

$$p_1 = \frac{4}{52} \approx 0.0769$$

Si en la primera extracción sí se obtuvo un as, la probabilidad en la segunda es:

$$p_2 = \frac{3}{51} \approx 0.0588$$

Si en la primera extracción no se obtuvo un as, la probabilidad cambia a:

$$p_2 = \frac{4}{51} \approx 0.0784$$

La probabilidad no es constante y cada resultado depende del anterior, los dos supuestos fundamentales de la Binomial se violan.

¿Qué modelo corresponde correctamente?

Este escenario se modela con la Distribución Hipergeométrica, cuya PMF es:

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$$

Donde:

$N = 52 \rightarrow$ tamaño de la población (baraja total)

$K = 4 \rightarrow$ ases en la baraja

$n \rightarrow$ número de cartas extraídas

$k \rightarrow$ número de ases deseados

Esta distribución sí modela poblaciones finitas sin reemplazo, donde los ensayos son dependientes.

Usar la Distribución Binomial en este escenario produciría probabilidades incorrectas, porque asume independencia entre ensayos y probabilidad constante, condiciones que se cumplen únicamente cuando el muestreo es

con reemplazo. El modelo estadísticamente correcto es la Distribución Hipergeométrica.

- En la Tarea 3 de su proyecto (ABP), ¿qué limitaciones existen al asumir que la tasa media (λ) calculada de su dataset permanece constante a lo largo de todo el periodo de estudio? ¿Se cumple la propiedad de estacionariedad?

Limitaciones principales:

Asumir que la tasa media $\lambda = 30.13$ horas permanece constante a lo largo de todo el periodo implica que el proceso es estacionario, es decir, que la frecuencia de ocurrencia del fenómeno no cambia con el tiempo. Esto rara vez se cumple en la práctica por varias razones [1]:

1. **Variabilidad temporal:** Las horas suplementarias dependen de factores estacionales (fin de año, auditorías, picos de demanda institucional). En ciertos meses habrá más horas extra que en otros, lo que rompe la constancia de λ .
2. **Heterogeneidad entre empleados:** El dataset mezcla puestos con regímenes laborales muy distintos. Algunos empleados tienen 0 horas (78.9% del dataset) mientras otros llegan a 523 horas. Un único λ global no representa bien a ningún subgrupo.
3. **Cambios estructurales:** Cambios de normativa, de autoridades o de presupuesto institucional pueden alterar la tasa real de horas extra a lo largo del tiempo.

La propiedad de estacionariedad no se cumple adecuadamente. La distribución empírica está fuertemente sesgada a la izquierda (como se ve en la gráfica de la Tarea 3), lo que indica que λ no es representativo de la mayoría de los empleados.

- Si $X \sim \text{Poisson}(\lambda)$, sabemos teóricamente que $E[X] = \lambda$ y $V[X] = \lambda$. ¿Se cumple esta propiedad (media igual a varianza) en la variable de conteo que extrajo de su dataset regional? Calcule ambos estadísticos muestrales y comente.

La propiedad teórica de Poisson exige que la media y la varianza sean iguales.

Con los datos reales de la variable "Horas suplementarias y extraordinarias":

Estadístico	Valor
Media muestral (λ)	30.1286
Varianza muestral	4,544.08
Ratio Varianza/Media	150.82

La varianza es aproximadamente 150 veces mayor que la media. Esto es una señal de sobredispersión severa, y significa que la propiedad $E[X] = V[X]$ no se cumple en absoluto para esta variable [2].

Interpretación:

La razón es estructural: el 78.9% de los empleados tiene exactamente 0 horas suplementarias, mientras que una minoría concentra valores muy altos (hasta 523 horas). Esta distribución altamente asimétrica e inflada en cero es incompatible con el supuesto de Poisson. Un modelo más adecuado para estos datos sería una distribución Binomial Negativa o un modelo Zero-Inflated Poisson (ZIP), que manejan mejor la sobredispersión y el exceso de ceros.

- **A partir de la investigación en la Tarea 4 (ABI), ¿cuáles son los umbrales prácticos (valores comúnmente aceptados en la literatura estadística de n y p) para considerar que la aproximación de Poisson a la Binomial es segura y válida?**

De acuerdo con el libro de Walpole, la aproximación de la distribución binomial mediante la distribución de Poisson es válida bajo ciertas condiciones relacionadas con sus parámetros. En primer lugar, esta aproximación es adecuada cuando el número de ensayos n es suficientemente grande y la probabilidad de éxito p es muy pequeña, es decir, cercana a cero. En este caso, no se establece un valor numérico exacto, sino una condición de comportamiento de los parámetros.

Desde el punto de vista teórico, se establece que la distribución binomial puede aproximarse a la distribución de Poisson cuando n es muy grande y p tiende a cero, siempre que el producto np permanezca constante, definido como μ . Este parámetro μ representa la media de la distribución de Poisson y es el que se utiliza en la práctica para realizar la aproximación mediante $\mu = np$ [3].

Además, el libro señala que incluso cuando p es cercano a 1, la aproximación puede aplicarse si se redefinen los eventos de éxito y fracaso, de modo que la probabilidad de éxito sea pequeña y se cumplan nuevamente las condiciones requeridas para la aproximación de Poisson [3].

A diferencia de la aproximación normal a la binomial, donde sí se establecen criterios numéricos como $np \geq 5$ y $nq \geq 5$, en la aproximación de Poisson el autor utiliza condiciones cualitativas. Sin embargo, los ejemplos del texto muestran su aplicación en casos como $n = 400$, $p = 0.005$ y $n = 800$, $p = 0.001$, lo que evidencia que la aproximación es válida cuando se trata de eventos raros y un número elevado de ensayos [3].

- **Si $X \sim \text{Poisson}(\lambda)$, sabemos teóricamente que $E[X] = \lambda$ y $V[X] = \lambda$. ¿Se cumple esta propiedad (media igual a varianza) en la variable de conteo que extrajo de su dataset regional? Calcule ambos estadísticos muestrales y comente.**

La distribución de Poisson, denotada como $X \sim \text{Poisson}(\lambda)$, se caracteriza por la propiedad de equidispersión. Matemáticamente, esto implica que el primer momento (media) y el segundo momento central (varianza) deben ser idénticos:

$$E[X] = V[X] = \lambda$$

2. Cálculo de Estadísticos Muestrales

Utilizando los datos del archivo de remuneraciones, se han calculado los estimadores para la media y la varianza de la variable "Horas suplementarias y extraordinarias":

Estadístico	Símbolo	Valor Calculado
Media Muestral	$\bar{x}$	30.1286
Varianza Muestral	s^2	4,544.08
Índice de Dispersión	$s^2 / \bar{x}$	150.82

Al contrastar los valores obtenidos, se determina que no se cumple la propiedad de equidispersión. En este dataset, la varianza es aproximadamente 150 veces mayor que la media, lo que evidencia un fenómeno de sobredispersión severa.

Esta discrepancia se fundamenta en la estructura de la nómina institucional:

- **Inflación de Ceros:** El 78.9% de los empleados no registra horas suplementarias, concentrando la masa de probabilidad en cero.
- **Valores Atípicos:** La presencia de empleados con una carga extraordinaria (hasta 523 horas) dispara la variabilidad.

Referencias:

- [1] A. C. Cameron, "Count Data Models for Financial Data," University of California, Davis, Working Paper, 1996.
- [2] H. Campbell et al., "The consequences of checking for zero-inflation and overdispersion in the analysis of count data," *Methods in Ecology and Evolution*, vol. 12, no. 4, pp. 665–680, Feb. 2021. doi: 10.1111/2041-210X.13559
- [3] R. E. Walpole, R. H. Myers, S. L. Myers y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9.ª ed., México: Pearson Educación, 2012

8. Rúbrica de Evaluación

Criterio Evaluado (Puntaje Máximo)	Nivel 3: Excelente (100%)	Nivel 2: Satisfactorio (50% - 75%)	Nivel 1: Insuficiente (0% - 49%)
1. Modelado Binomial y Poisson (2.5 pts)	Tareas 1 y 2 correctas: código funcional, incluye gráficas PMF/CDF y cálculo de probabilidad exacto.	Tareas completadas con errores menores en código/gráficos o un error en el cálculo de probabilidad.	Tarea incompleta o código no funcional. No hay gráficos ni cálculos.
2. Aplicación Proyecto (ABP) (3.0 pts)	Tarea 3 completa: identifica y justifica la variable de conteo, calcula λ empírico, y genera la superposición Histogram-PMF con análisis.	Tarea completada, pero con λ incorrecto o fallos de formato/visualización en el gráfico de superposición.	Tarea 3 no realizada o variable seleccionada no es de conteo discreta.
3. Demostración asintótica (ABI) (1.5 pts)	Tarea 4 correcta: explicación teórica de la relación $n \rightarrow \infty$ y $p \rightarrow 0$, y script Python que demuestra la convergencia.	Bloque Markdown ambiguo/incompleto, o script que no demuestra claramente la aproximación.	Tarea 4 no realizada (código y explicación teórica ausentes).
4. Preguntas de Control (2.0 pts)	Responde las 5 preguntas de manera clara,	Responde 3 o 4 preguntas. Las justificaciones son	Responde 2 preguntas o menos. Las



Criterio Evaluado (Puntaje Máximo)	Nivel 3: Excelente (100%)	Nivel 2: Satisfactorio (50% - 75%)	Nivel 1: Insuficiente (0% - 49%)
	fundamentada y con notación estadística correcta.	superficiales o con errores menores en notación.	respuestas son incorrectas o sin fundamento teórico.
5. Organización y Estilo de Código (1.0 pts)	Notebook profesional con estructura lógica, celdas Markdown legibles y comentarios pertinentes.	Formato inconsistente o falta de comentarios clave. Estructura aceptable.	Código ilegible o sin comentar. No utiliza celdas Markdown o la estructura es desordenada.

9. Bibliografía

Liste las fuentes utilizadas. Use normas **IEEE**. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	